

# Računalni vid

## Elementarne slikovne značajke

Siniša Šegvić

UniZg-FER D307

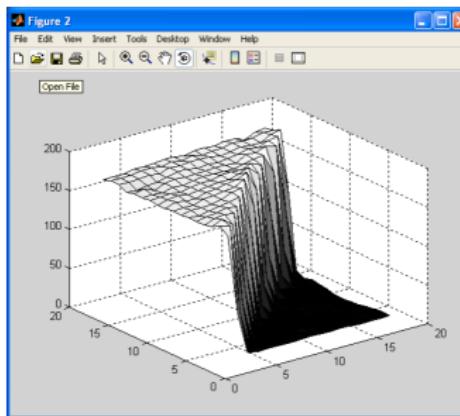
Sveučilište u Zagrebu

# PLAN

1. Gradijenti i glađenje
2. Rubovi
3. Ključne točke

# GRADIJENT. SLIKA KAO FUNKCIJA

Slike često tretiramo kao kontinuirane funkcije



[collins07cse486]

Prednost: analiza primjenom alata matematičke analize

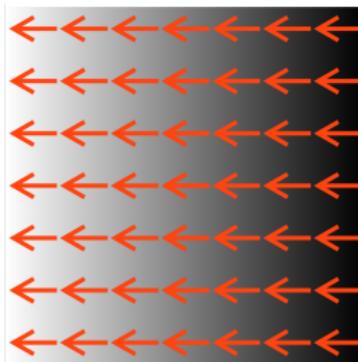
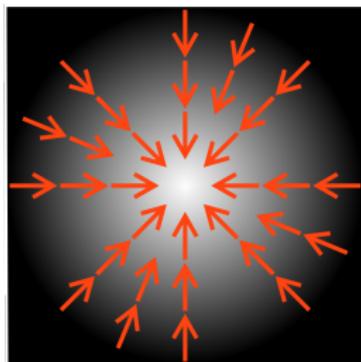
- rubovi objekata imaju veliki **gradijent**
- okna s "nejednolikim" gradijentom pogodna za **korespondenciju**
- u drugoj slici iste scene, lakat ćemo lakše prepoznati od nadlaktice

## GRADIJENT. FORMULACIJA

Gradijent kontinuirane skalarne funkcije dvije varijable:

$$\nabla I(\mathbf{q}) = \partial I / \partial \mathbf{q} = [I_x(\mathbf{q}), I_y(\mathbf{q})]$$

Gradijent možemo interpretirati kao smjer najbržeg rasta sive razine:

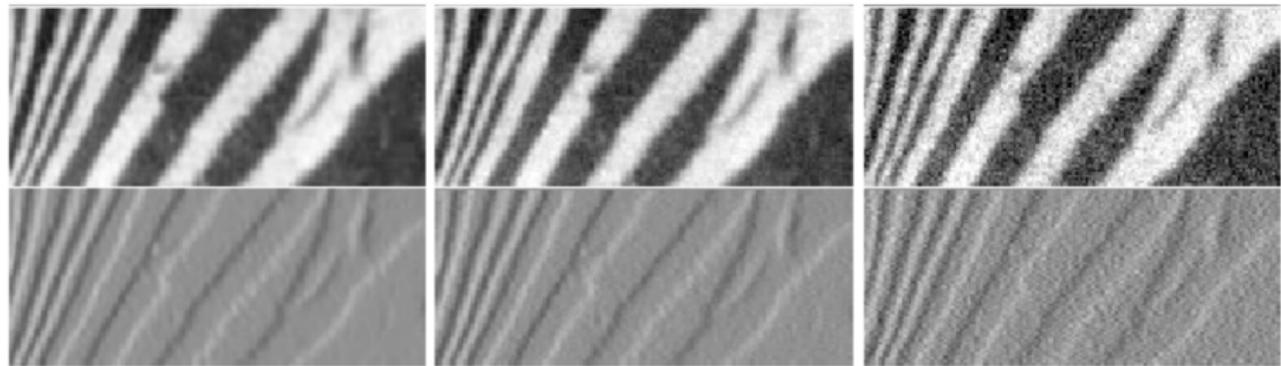


[Wikipedia]

## GRADIJENT. ŠUM

Međutim, deriviranje se loše ponaša u prisustvu šuma

- prvi redak: slike s rastućim udjelom šuma
- drugi redak: aproksimacija negativnog horizontalnog gradijenta konačnim razlikama



[ponce12book]

Vidimo da deriviranje naglašava šum

- zbog toga prije deriviranja obično primjenjujemo glađenje

## GRADIJENT. GLAĐENJE

Jače glađenje tolerira više šuma ali i gubi fine detalje



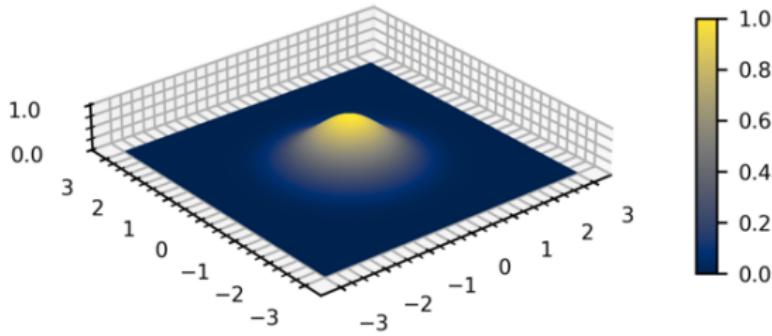
[lindeberg08wiley]

## GRADIJENT. GAUSS

Optimalnu detekciju rubova osigurava glađenje koje možemo aproksimirati konvolucijom s dekoreliranim Gaussom [canny86pami]

- svaki piksel mijenjamo s prosjekom njegovog susjedstva
- bliži susjedi su važniji
- važno svojstvo: separabilnost

$$f(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$$



[Wikipedia]

## GRADIJENT. GAUSS (2)

Glađenje je elementarna operacija predobrade koju ima smisla koristiti i ako ne ciljamo na rubove

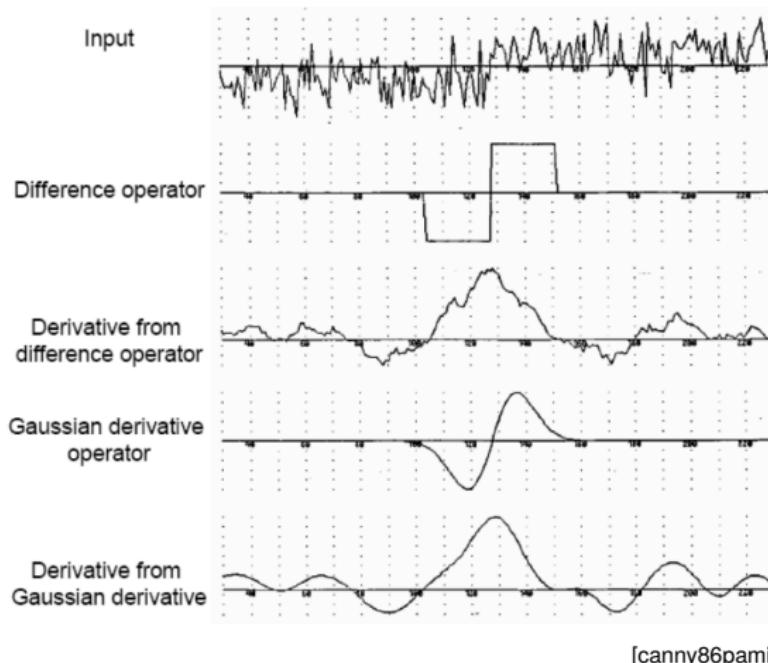


[segvic00ms]

## GRADIJENT. RECEPT

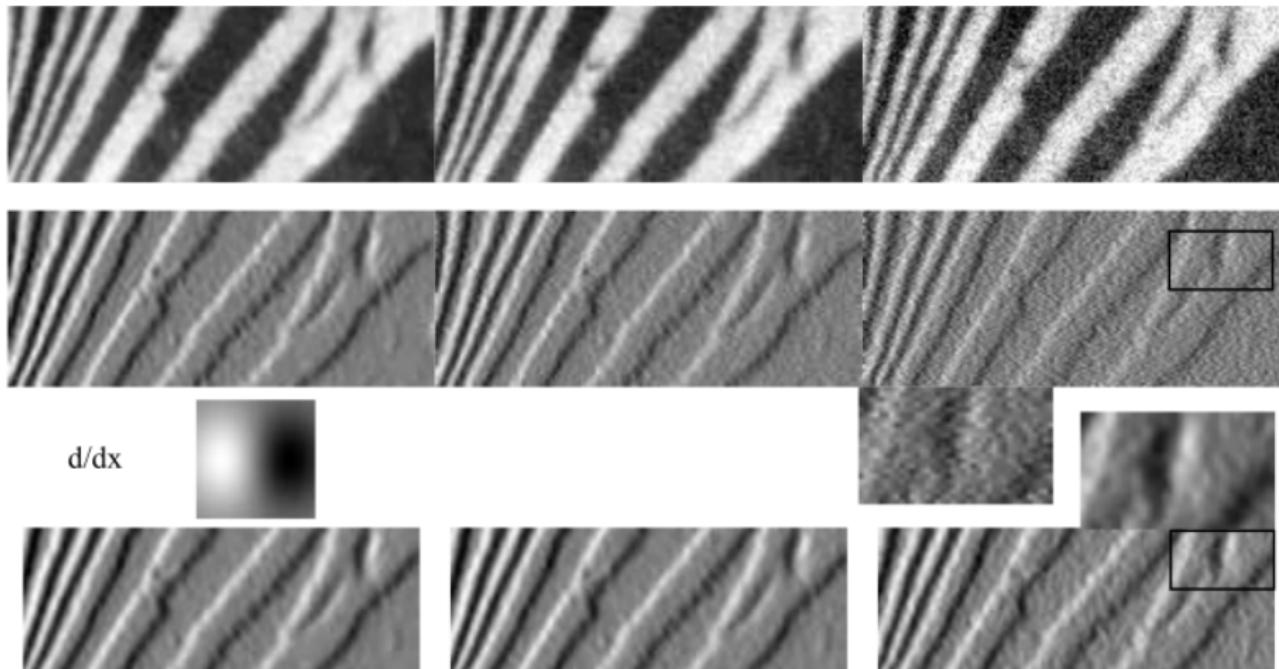
Aproksimirati gradijente konvolucijom s derivacijom Gaussovog filtra

- dva koraka mogu se stopiti u jedan
- konvolucije i derivacije su asocijativne



## GRADIJENT. RECEPT (2)

Gradijente je bolje aproksimirati konvolucijom s derivacijom Gaussa nego konačnim diferencijama



[ponce12book]

## GRADIJENT. SEPARABILNA IZVEDBA

I gauss i derivirani Gauss su **separabilni 2D filtri**: 2D konvolucija s takvim filtrima može se izvesti uz pomoć dvije 1D konvolucije.

Ako nam se žuri, gradijente možemo aproksimirati i konačnim razlikama u zaglađenoj slici.

Jako važno za primjene u stvarnom vremenu, posebno ako postupak koristi slikovne piramide.

Gaussov filter može se aproksimirati rekurzivnim binomnim filtrom (dodatno ubrzanje).

# RUBOVI

Rubovi upućuju na granice objekata:

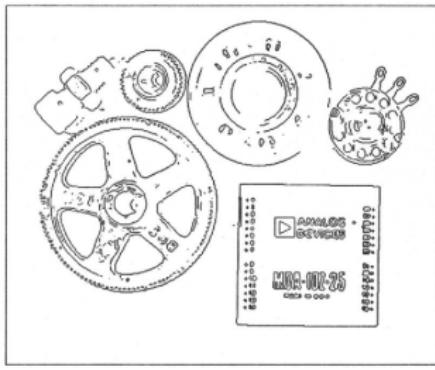
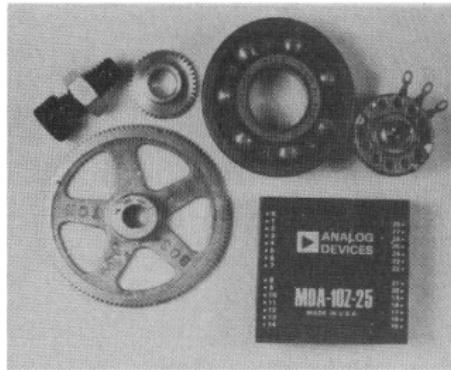
- **oblik:** inherentno svojstvo objekta
- teže ga je sakriti od **teksture**
- organizmi koji vide oblik imaju evolucijsku prednost



[biologyonline,flickr]

## RUBOVI: MOTIVACIJA

Rane metode iz romantičarske faze računalnog vida imale su ambiciju detektirati objekte analizom rubova:



[canny86pami]

- kasnije smo spoznali da to ipak ne bi išlo samo tako :-)
- da bi znao iscrtati rub objekta - moraš razumjeti gdje je objekt
- gradijent je presirova informacija za tako zahtjevan zadatak
- ipak, stečena iskustva mogu dati korisnu intuiciju pri razvoju modernih metoda

# RUBOVI: CANNYJEV ALGORITAM

Jedan od najstarijih i najdosljednijih detektora rubova

Glavni koraci algoritma:

1. računanje gradijenta konvolucijom s deriviranim Gaussom
  - možemo i aproksimirati konačnim razlikama u zaglađenoj slici
  - ne puno lošije, do  $2\times$  brže
2. stanjivanje rubova potiskivanjem ne-maksimalnih odziva u smjeru pružanja gradijenta
  - ideja je rubove smjestiti u točkama infleksije profila sive razine uzduž smjera gradijenta
  - dobro za lokalizaciju rubova
3. (opcionalno) potisnuti rubove s malenim gradijentom usporedbom s unaprijed zadanim histereznim pragom

## RUBOVI: CANNYJEV ALGORITAM (2)

### 1. Računanje gradijenta konvolucijom s deriviranim Gaussom

- tipično - Sobelov operator

X – Direction Kernel

-1	0	1
-2	0	2
-1	0	1

Y – Direction Kernel

-1	-2	-1
0	0	0
1	2	1

- rezultat: dvije slike gradijenata, u x i y smjeru ( $G_x$ ,  $G_y$ )
- iznos i smjer gradijenta:

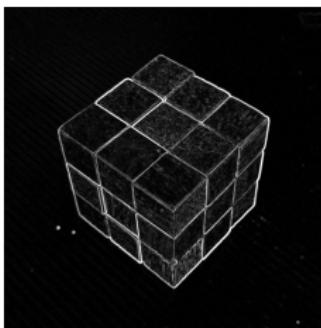
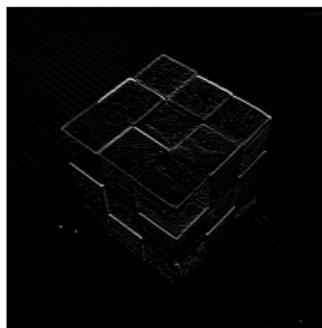
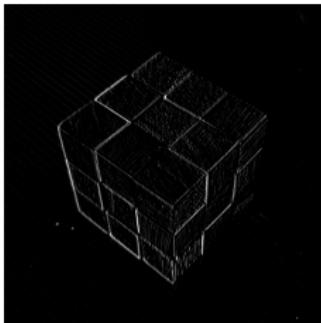
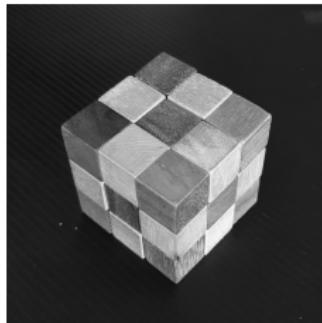
$$|G| = \sqrt{G_x^2 + G_y^2}$$

$$\theta = \arctan(G_y / G_x)$$

## RUBOVI: CANNYJEV ALGORITAM (3)

### 1. Računanje gradijenta konvolucijom s deriviranim Gaussom (2)

- Sobelov operator - primjer: gornji red: izvorna slika,  $G_x$ ; donji red:  $G_y$ ,  $|G|$

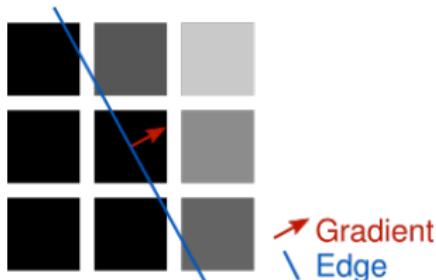


Napomena:  $G_x$  i  $G_y$  mogu biti i pozitivni i negativni - na slici su prikazane absolutne vrijednosti

## RUBOVI: CANNYJEV ALGORITAM (4)

2. Stanjivanje rubova potiskivanjem ne-maksimalnih odziva u smjeru pružanja gradijenta

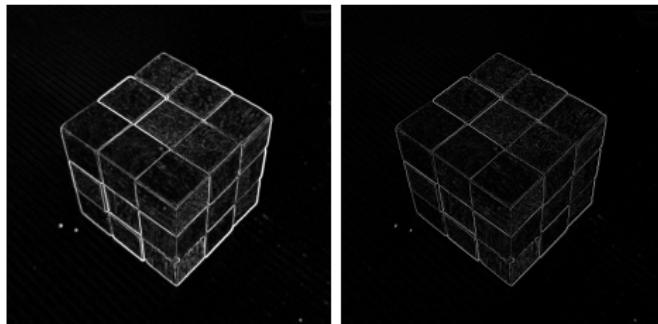
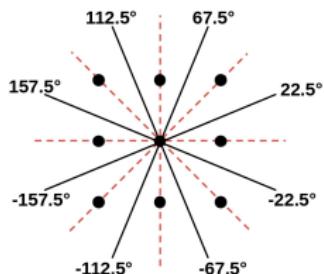
- rezultat računanja gradijenata je slika rubova, ali često širokih i nekoliko piksela (neprecizna lokalizacija)
- težimo preciznijoj lokalizaciji značajki
- ideja: svaki piksel u slici  $|G|$  usporediti s njegova dva susjeda u smjeru gradijenta (okomit na smjer pružanja ruba) i zadržati samo one koji imaju veći iznos gradnjenta od svojih susjeda (ostale postavljamo na 0)



## RUBOVI: CANNYJEV ALGORITAM (5)

2. Stanjivanje rubova potiskivanjem ne-maksimalnih odziva u smjeru pružanja gradijenta (2)

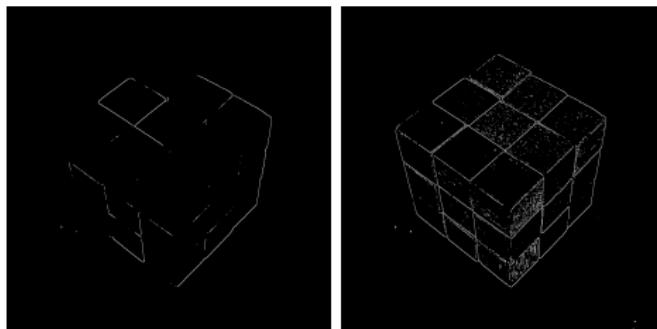
- pri tome, smjerove gradijenta diskretiziramo u 8 pravaca



## RUBOVI: CANNYJEV ALGORITAM (6)

3. Potiskivanje rubova s malenim gradijentom usporedbom s unaprijed zadanim histereznim pragom

- binarizacija rubova usporedbom s pragovima
- $|G| > T_1$  - sigurno rub ("jaki rubovi")
- $T_1 \geq |G| \geq T_2$  - potencijalno rub (slabi rubovi)
- $|G| < T_2$  - sigurno nije rub



lijevo - jaki rubovi; desno - svi rubovi

## RUBOVI: CANNYJEV ALGORITAM (7)

Literatura: <https://ieeexplore.ieee.org/document/4767851>

Detalji: <https://cvunizg.github.io/lab/lab2/>

## KLJUČNE TOČKE

**Značajka:** istaknuti dio slike

- izgled i položaj **prepoznatljivi** iz različitih dijelova scene  
(kut, blob, ...)
- zbog efikasnije implementacije, najčešći kvadratni oblik  
(koriste se i pravokutnici, paralelogrami, krugovi, ...)

**veličina značajke:** kompromis između **otpornosti na zaklanjanje** i  
**neprepoznatljivosti**

**svojstveno mjerilo i rotacija:** noviji koncept, problemi u stvarnom  
vremenu (GPGPU!)

## PRONALAŽENJE KUTEVA

**Značajka:** istaknuti dio slike

- izgled i položaj **prepoznatljivi** iz različitih dijelova scene  
(kut, blob, ...)
- zbog efikasnije implementacije, najčešći kvadratni oblik  
(koriste se i pravokutnici, paralelogrami, krugovi, ...)

**veličina značajke:** kompromis između **otpornosti na zaklanjanje** i  
**neprepoznatljivosti**

**svojstveno mjerilo i rotacija:** noviji koncept, problemi u stvarnom  
vremenu (GPGPU!)

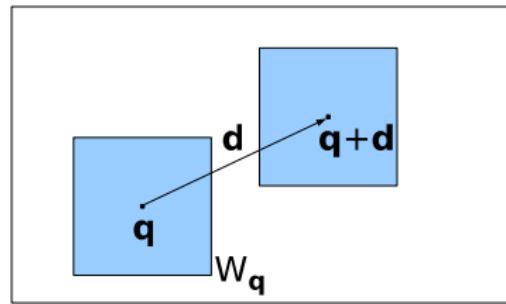
## PRONALAŽENJE KUTEVA

**Harrisovi kutevi:** unatoč poodmakloj dobi (1988), jedan od najefikasnijih pristupa s fiksnim mjerilom

**Ideja:** pronaći točke  $\mathbf{q}_{zn}$  koje maksimiraju lokalnu prepoznatljivost susjedstva ***zadane veličine***

**Promotrimo** ``autokorelacijsku funkciju'' (zapravo **SSD**):

$$E_{\mathbf{q}}(\mathbf{d}) = \sum_{x,y \in W(\mathbf{q})} [I(x+d_x, y+d_y) - I(x, y)]^2$$



$E_{\mathbf{q}}(\mathbf{d})$ : različitost susjedstva točke  $\mathbf{q}$ , u ovisnosti o pomaku  $\mathbf{d}$

## PRONALAŽENJE KUTEVA

**Ideja:** značajke su u točkama gdje  $E_q$  raste u svim smjerovima!

Tražimo kriterij koji će otkriti točke  $\mathbf{q}(x_{zn}, y_{zn})$  gdje to vrijedi.

**Rezultat:** U svakoj točki slike računa se matrica  $\mathbf{G}$

- $\mathbf{G}$  sadrži lokalne iznose momenata drugog reda gradijenta slike

$$\mathbf{G}(\mathbf{q}) = \begin{bmatrix} \sum_w I_x^2 & \sum_w I_x I_y \\ \sum_w I_x I_y & \sum_w I_y^2 \end{bmatrix} = \begin{bmatrix} a & c \\ c & b \end{bmatrix} \quad (1)$$

**Harrisov odziv**  $r$  sada je:  $r(\mathbf{q}) = ab - c^2 - k(a + b)^2$

Konačno, značajke su u lokalnim maksimumima odziva:

$$\mathbf{q}_{zn} = \max_{\mathbf{q}} r(\mathbf{q})$$

# PRONALAŽENJE KUTEVA

## Izvod Harrisove formule

Zapišimo  $E$  u vektorskem obliku:

$$\begin{aligned} E_{\mathbf{q}}(\mathbf{d}) &= \sum_{x,y \in W(\mathbf{q})} [I(x+d_x, y+d_y) - I(x, y)]^2 \\ &= \sum_{\mathbf{q}_i \in W(\mathbf{q})} [I(\mathbf{q}_i + \mathbf{d}) - I(\mathbf{q}_i)]^2 \end{aligned}$$

# PRONALAŽENJE KUTEVA

## Izvod Harrisove formule (2)

Razvijmo  $I(\mathbf{q}_i + \mathbf{d})$  po Tayloru oko  $\mathbf{q}_i$ :

$$\begin{aligned} E_{\mathbf{q}}(\mathbf{d}) &= \sum_{\mathbf{q}_i \in W_q} [I(\mathbf{q}_i + \mathbf{d}) - I(\mathbf{q}_i)]^2 \\ &\approx \sum_{\mathbf{q}_i \in W} [I(\mathbf{q}_i) + \nabla I(\mathbf{q}_i) \cdot \mathbf{d} - I(\mathbf{q}_i)]^2 \end{aligned}$$

$$\begin{aligned} E_{\mathbf{q}}(\mathbf{d}) &\approx \sum_{\mathbf{q}_i \in W} [g^T \mathbf{d}]^2 = \sum_{\mathbf{q}_i \in W} \mathbf{d}^T (gg^T) \mathbf{d} \\ &= \mathbf{d}^T \cdot \mathbf{G} \cdot \mathbf{d}, \quad \text{gdje je } \mathbf{G} = \sum_W gg^T \end{aligned}$$

Podsjetnik:  $\nabla I(\mathbf{q}_i) = g^T = [I_x(\mathbf{q}_i), I_y(\mathbf{q}_i)]$

# PRONALAŽENJE KUTEVA

## Izvod Harrisove formule (3)

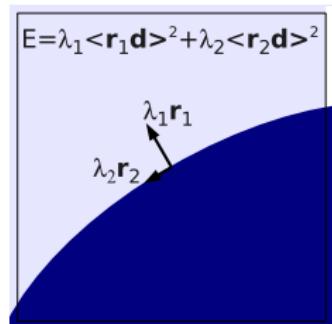
Matrica  $G$  je realna i simetrična pa se može dijagonalizirati:

$$G = \begin{bmatrix} \sum_w I_x^2 & \sum_w I_x I_y \\ \sum_w I_x I_y & \sum_w I_y^2 \end{bmatrix} = R^\top D R, \text{ gdje je } R = \begin{bmatrix} r_1^\top \\ r_2^\top \end{bmatrix}$$

Sada kriterijsku funkciju možemo izraziti u koordinatama koje su poravnate s lokalnom strukturom slike:

$$E_q(\mathbf{d}) = \mathbf{d}^\top \cdot G \cdot \mathbf{d} = \sum_{q_i \in W} \mathbf{d}_R^\top \cdot D \cdot \mathbf{d}_R,$$

$$\mathbf{d}_R = R \cdot \mathbf{d} = [r_1^\top d, r_2^\top d]^\top$$



# PRONALAŽENJE KUTEVA

## Izvod Harrisove formule (4)

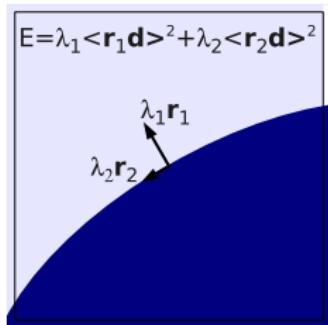
U novim koordinatama, doprinosi komponenti pomaka **nezavisno** utječu na kriterijsku funkciju E!

$$E_q(\mathbf{d}) = \mathbf{d}^T \cdot \mathbf{G} \cdot \mathbf{d} = \mathbf{d}_R^T \cdot \mathbf{D} \cdot \mathbf{d}_R$$

$$= \mathbf{d}_R^T \cdot \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} \cdot \mathbf{d}_R$$

$$= \lambda_1 d_{R1}^2 + \lambda_2 d_{R2}^2$$

$$= \lambda_1 (\mathbf{r}_1^T \mathbf{d})^2 + \lambda_2 (\mathbf{r}_2^T \mathbf{d})^2$$



Slika se lokalno brzo mijenja u svim smjerovima  $\Leftrightarrow \lambda_1, \lambda_2$  veliki!

## PRONALAŽENJE KUTEVA

**Harrisov odziv** ``nagrađuje" točke u kojima su veliki i  $\lambda_1$  i  $\lambda_2$ :

$$\mathbf{G} = \begin{bmatrix} \sum_w I_x^2 & \sum_w I_x I_y \\ \sum_w I_x I_y & \sum_w I_y^2 \end{bmatrix} = \begin{bmatrix} a & c \\ c & b \end{bmatrix}$$

$$\begin{aligned} r &= ab - c^2 - k \cdot (a + b)^2 \quad k \in [0.04, 0.07] \\ &= \det(\mathbf{G}) - k \cdot (\text{tr}^2(\mathbf{G})) \\ &= \lambda_1 \lambda_2 - k \cdot (\lambda_1 + \lambda_2)^2 \end{aligned}$$

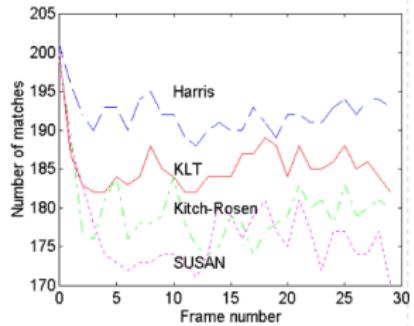
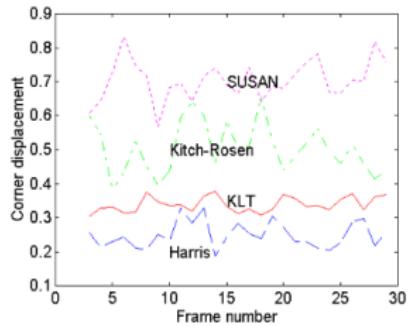
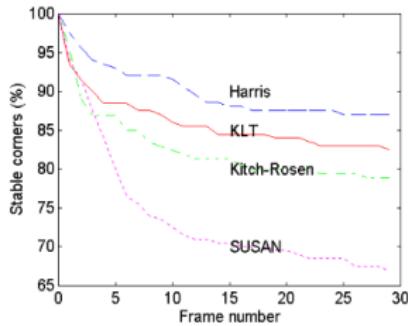
Konačni rezultat su lokalni maksimumi odziva

Potiskivanje ne-maksimalnih odziva dovodi do dobre lokalizacije značajki

# PRONALAŽENJE KUTEVA



Broj značajki (a), lokalizacija (b), te uspješnost uparivanja (c):

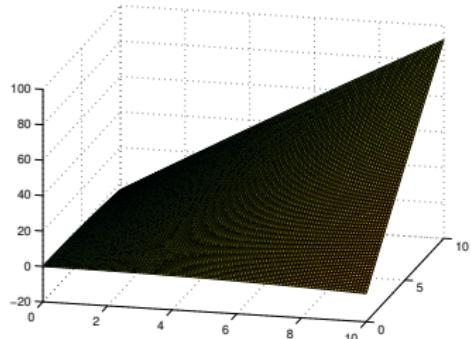
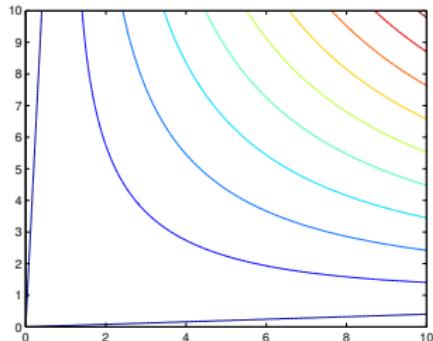


[tissainayagam04imavis]

# PRONALAŽENJE KUTEVA

Oblik funkcije odziva:

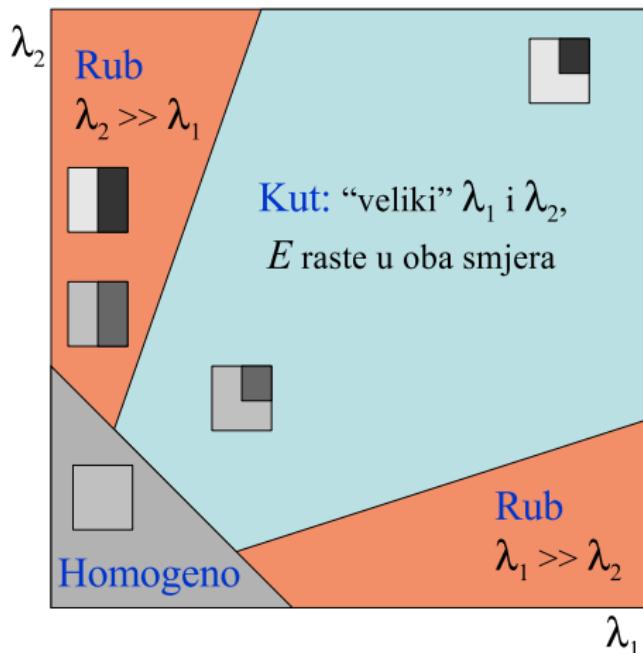
$$r = \lambda_1 \lambda_2 - k \cdot (\lambda_1 + \lambda_2)^2$$



# PRONALAŽENJE KUTEVA

Oblik funkcije odziva (2):

$$r = \lambda_1 \lambda_2 - k \cdot (\lambda_1 + \lambda_2)^2$$



# PRONALAŽENJE KUTEVA

## Detalji:

- težinska funkcija?  $\mathbf{G} = \sum_W w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$
- derivacijsko i integracijsko mjerilo?

## Svojstva:

- odziv (pa onda i maksimum) invarijantan na rotaciju slike!
- dobra ponovljivost i lokalizacija rezultata  
(barem za jednostavne značajke)
- problem: odziv nije invarijantan na mjerilo!

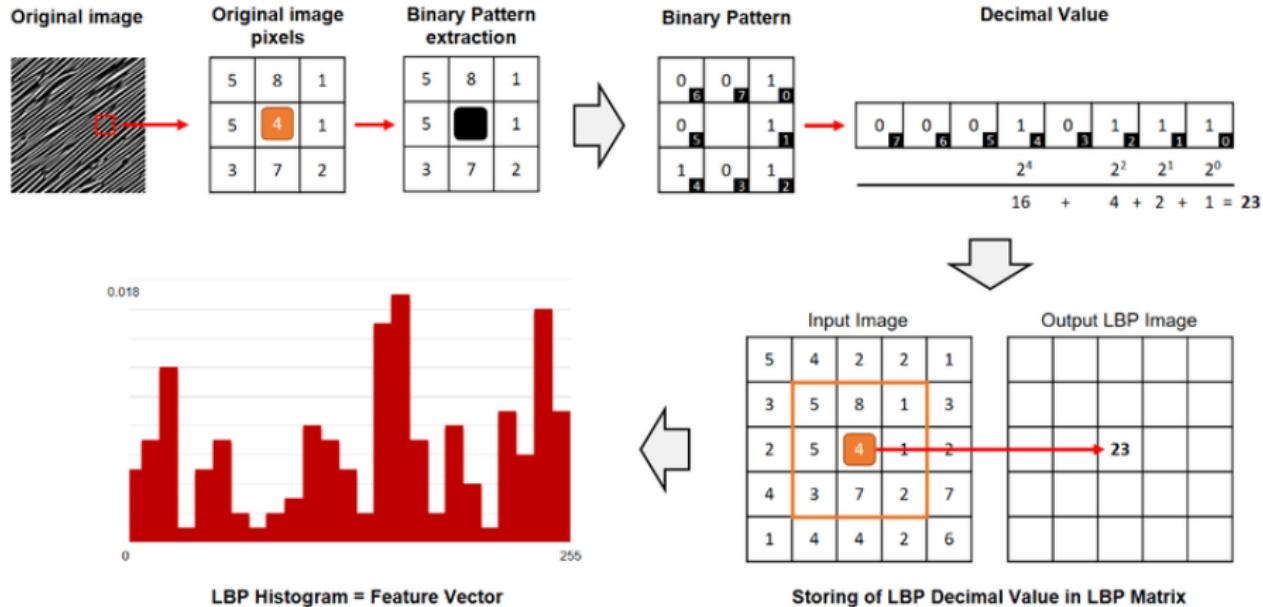
## Alternative:

- FAST (brži); DoG, MSER, SURF (invarijantni na mjerilo, sporiji)

## LOKALNI BINARNI UZROCI

- **LBP** (engl. local binary patterns)
- jednostavan operator za opis teksture
- neosjetljiv na promjene u osvjetljenju
- slična ideja: **Census** transformacija
- primjene
  - opis tekstura
  - podudaranje značajki
  - prisustvo rubova i kuteva

## LOKALNI BINARNI UZROCI



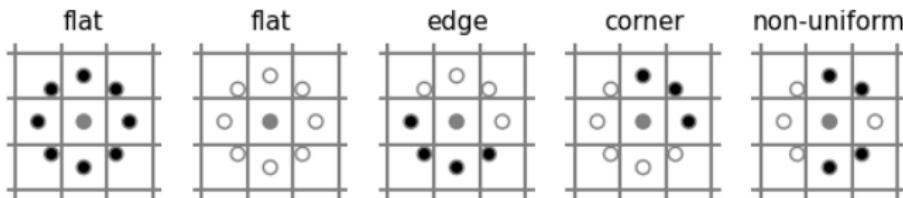
## LOKALNI BINARNI UZROCI

**Postupak:** za svaki piksel u izvornoj (sivoj) slici:

- usporedi vrijednost piksela sa svim pikselima u nekom njegovom susjedstvu (tipično  $3 \times 3$ )
- ako je središnji piksel manji od piksela okoline, to označavamo s 0
- ako je središnji piksel veći od piksela okoline, to označavamo s 1
- rezultat: bitovni niz koji očitavamo nekim predefiniranim redoslijedom i pretvaramo u dekadski broj
- (kod analize tekstura slika se dijeli na čeije i za svaku ćeliju konstruira se LBP histogram - opis lokalne tekture)

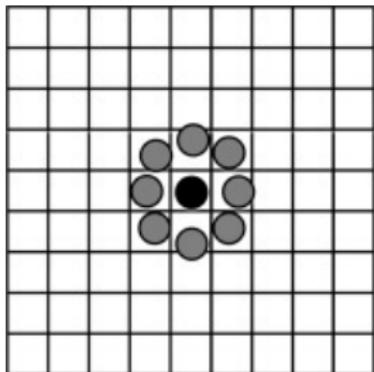
## LOKALNI BINARNI UZROCI

- LBP enkodira prisustvo tipičnih značajki (rubova, kuteva, ...) u promatranom lokalnom području

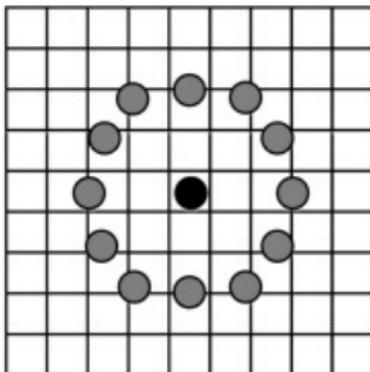


## LOKALNI BINARNI UZROCI

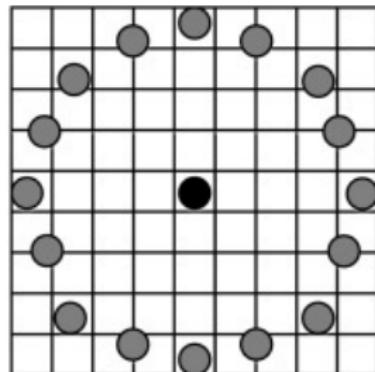
- Moguće su i drugčije veličine okoline



$P=8, R=1$



$P=12, R=2$



$P=16, R=4$

## ZAHVALA

Ova predavanja proizšla su iz istraživanja koje je financirala Hrvatska zaklada za znanost projektom ADEPT.

<http://adept.zemris.fer.hr>